

Lucrare laborator

Componenta b)

Autor: Farcas Andrei-Catalin

Grupa: 232

April 20, 2026

1 Prima cerinta - Analiza problemei

Problema pe care doreste acest proiect software sa o abordeze este numarul scazut de lucrari stiintifice care trateaza separat traficul de tip network fuzzing (dar si restul tipurilor de atac) in contextul antrenarii si evaluarii modelelor de machine learning in vederea detectarii anomalilor din traficul de internet. Asadar, am selectat 4 lucrari stiintifice care au abordat intr-o masura nesatisfacatoare problema relatata mai devreme. Aceste lucrari prezinta antrenarea de diferiti algoritmi de machine learning pe 3 seturi de date diferite, dar si rezultatele acestora in vederea identificarii traficului de internet malitios.

1. Improving Network Security through Fuzzing Attack Detection: Machine Learning on the Kitsune Dataset - Yousef Abuzir, Dima Raed Abu Khalil (2025) [[AAK25](#)]
 - **Contributie:** Compararea a trei tehnici de ML (LDA, Logistic Regression si un model hibrid CNN-GRU-LSTM) pentru detectarea atacurilor de tip fuzzing pe setul de date Kitsune, incluzand utilizarea SHAP pentru interpretarea importantei trasaturilor.
 - **Rezultate:** Modelul hibrid a obtinut o acuratete de 99.66%, in timp ce Regresia Logistica a atins performante perfecte dupa eliminarea valorilor aberante (outliers). LDA a avut performante slabe pe clasa malitioasa (Recall 0.24).
 - **Limitari:** Modelele hibride au costuri computationale ridicate si timpi de testare lungi. LDA are dificultati majore in gestionarea seturilor de date dezechilibrate.
2. Machine Learning Approach for Improvement in Kitsune NID - Abdullah Alabdulatif, Syed Sajjad Hussain Rizvi (2022) [[AR22](#)]
 - **Contributie:** Analiza comparativa a variantelor de algoritmi Decision Tree (Fine, Medium, Coarse, Boosted, Bagged, RUS Boosted) pe setul de date Kitsune pentru a identifica cel mai eficient model pentru detectia intruziunilor.
 - **Rezultate:** Fine Tree si Medium Tree au obtinut o acuratete de 99.99% si un TPR de 100% pentru clasa de fuzzing. Boosted Tree a performat surprinzator de slab (TPR 80%).
 - **Limitari:** Studiul este limitat la algoritmi bazati pe arbori si evidentiaza faptul ca anumite variante (Boosted) sunt sensibile la natura adversariala a input-urilor de fuzzing.
3. An Intelligent Ensemble-Based Detection of In-Vehicle Network Intrusion - Easa Alalwany et al. (2025) [[AMAA25](#)]

- **Contributie:** Propune o schema de detectie bazata pe invatare de ansamblu (Stacking, Voting, Bagging) folosind RF, DT si XGBoost pentru atacurile pe magistrala CAN, incluzand echilibrarea datelor (Near-Miss) si selectia trasaturilor (Extra Trees).
 - **Rezultate:** Metoda de Stacking a obtinut cele mai bune rezultate pentru clasa de fuzzing (Acuratete 0.993, F1-score 1.00, ROC-AUC 1.00).
 - **Limitari:** Setul de date are doar 5 features pentru fuzzing.
4. Anomaly Detection with Various Machine Learning Classification Techniques over UNSW-NB15 Dataset - Martina Shushlevska et al. (2022) [SEJT22]
- **Contributie:** Evaluarea algoritmilor Naive Bayes, Logistic Regression, Decision Tree si Random Forest pe setul de date UNSW-NB15 pentru detectia anomaliilor.
 - **Rezultate:** Random Forest a demonstrat cele mai bune performante (F1-score 89.3%, Recall 98.5% pe evaluari generale).
 - **Limitari:** Studiul evidentiaza faptul ca antrenarea modelelor a fost realizata pe intreg setul de date fara o specializare pe clasele de atac, ceea ce poate dilua eficacitatea detectiei pentru atacuri specifice precum fuzzing-ul.

2 A doua cerinta - Solutia propusa

2.1 Descriere

Proiectul propune antrenarea si evaluarea comparativa a trei modele de Machine Learning (Random Forest, Decision Tree si Logistic Regression) specializate pe detectia traficului de tip "Fuzzers" din setul de date UNSW-NB15. Datele vor trece printr-o etapa de preprocesare (curatare, normalizare, transformare in format binar: Normal vs. Fuzzers) si selectie de feature-uri, urmata de antrenarea modelelor si compararea lor pe baza metricilor de performanta.

2.2 Motivatie

Atacurile de tip network fuzzing sunt extrem de sofisticate si pot pacali foarte usor sistemele de detectie generice. Lipsa lucrarilor stiintifice care sa trateze separat aceasta clasa de atac justifica necesitatea unui model dedicat. Random Forest si Decision Tree sunt alese pentru capacitatea lor ridicata de a modela relatii complexe in traficul de retea, in timp ce Logistic Regression ofera un baseline rapid.

2.3 Plan

Dataset-ul UNSW-NB15, set public, din care extragem doar inregistrarile etichetate ca "Fuzzers" si a traficului "Normal" pentru antrenament. Folosim Python 3, cu biblioteci Pandas, NumPy, Scikit-learn, Matplotlib, etc. Performanta o vom evalua dupa metricile Accuracy, Precision, F1, Recall, curba ROC-AUC, confusion matrix, etc.

References

- [AAK25] Yousef Abuzir and DR Abu Khalil. Improving network security through fuzzing attack detection: Machine learning on the kitsune dataset. *Computer Science and Information Technology*, 13(1):8–31, 2025.

- [AMAA25] Easa Alalwany, Imad Mahgoub, Bader Alsharif, and Abdullah Alfahaid. An intelligent ensemble-based detection of in-vehicle network intrusion. *Applied Sciences*, 15(12):6869, 2025.
- [AR22] Abdullah Alabdulatif and Syed Sajjad Hussain Rizvi. Machine learning approach for improvement in kitsune nid. *Intelligent Automation & Soft Computing*, 32(2), 2022.
- [SEJT22] Martina Shushlevska, Danijela Efnusheva, Goran Jakimovski, and Zdravko Todorov. Anomaly detection with various machine learning classification techniques over unsw-nb15 dataset. *Proceedings of International Conference on Applied Innovation in IT*, 10(1):21–27, 2022.