

Lucrare laborator

Componenta c)

Autor: Farcas Andrei-Catalin

Grupa: 232

May 8, 2026

1 Rezultate experimentale:

1.1 Setul de date: UNSW-NB15 (public)

1. Link: <https://research.unsw.edu.au/projects/unsw-nb15-dataset>
2. Tipul datelor: date reale de trafic de retea
3. Descriere: Setul de date a fost generat in laboratoarele Cyber Range ale UNSW Canberra, cu un numar total de 2.540.044 de inregistrari
4. Preprocesari:
 - Am folosit fisierele csv care au fost preprocesate din setul de date initial (headere adaugate), dar le-am concatenat, pentru a elimina un posibil bias.
 - am eliminat identificatorii irelevanti: id si etichetele de categorie de atac.
 - Imputarea valorilor lipsa/infinite cu mediana/zero.
 - Am codificat variabilele legate de categorii, folosind LabelEncoder (`proto`, `service`, `state`).
 - Am scalat datele pentru a uniformiza intervalele de valori ale caracteristicilor, prin StandardScaler.

1.2 Metrici de evaluare

Performanta modelelor a fost cuantificata folosind urmatoarele metrice:

- **Accuracy:** procentul de predictii corecte din totalul cazurilor. $Acc = \frac{TP+TN}{TP+TN+FP+FN}$
- **Recall:** capacitatea de a identifica corect toate atacurile fuzzing reale. $Rec = \frac{TP}{TP+FN}$
- **Precision:** procentul de atacuri reale din totalul intrarilor marcate ca atac. $Prec = \frac{TP}{TP+FP}$
- **F1=Score:** media armonica de discriminare a modelului intre clase pe diferite praguri de probabilitate. $F1 = 2 \cdot \frac{Prec \cdot Rec}{Prec+Rec}$
- **ROC-AUC:** masura a capacitatii de discriminare a modelului intre clase pe diferite praguri de probabilitate.

1.3 Metodologie de antrenare si evaluare

Antrenarea a fost supervizata si am folosit o paradigma de clasificare binara.

- **Impartire date:** S-a utilizat un stratified split de 80% pentru antrenament si 20% pentru testare, asigurand mentinerea distributiei claselor in ambele seturi.
- **Echilibrare:** Deoarece traficul normal domina numeric atacurile fuzzing, s-a aplicat algoritmul SMOTE (Synthetic Minority Over-sampling Technique) pe setul de antrenament, pentru a genera pachete sintetice de tip Fuzzers.
- **Arhitecturi si Hiperparametri:**
 - **Logistic Regression:** Configurat cu `max_iter=1000` pentru a asigura convergenta vectorului de ponderi pe datele scalate. Este un model liniar ce calculeaza probabilitatea apartenentei la o clasa folosind functia sigmoida, fiind ideal pentru a stabili un prag minim de performanta in separabilitatea datelor.
 - **Decision Tree:** S-a limitat adancimea maxima la `max_depth=10` pentru a preveni *overfitting*-ul pe zgomotul specific traficului de retea. Modelul fragmenteaza spatiul caracteristicilor in regiuni rectangulare prin reguli de decizie succesive, oferind o transparenta ridicata in identificarea pragurilor pentru attribute precum `sttl` sau `dbytes`.
 - **Random Forest:** Utilizeaza un ansamblu de `n_estimators=100` de arbori de decizie antrenati pe subseturi aleatorii de date (bagging). Prin agregarea voturilor, modelul reduce varianta si corecteaza tendinta arborilor individuali de a se specializa excesiv pe setul de antrenament, devenind mult mai robust in fata anomaliilor.
 - **XGBoost:** Algoritm de *Extreme Gradient Boosting* ce optimizeaza succesiv o functie de cost de tip `logloss`. Acesta construiește arbori noi pentru a corecta erorile reziduale ale arborilor anteriori, fiind extrem de eficient in capturarea relatiilor non-liniare complexe si a interdependentelor dintre protocoalele de retea.

1.4 Rezultate efective si analiza:

Analiza comparativa a relevat urmatoarele rezultate (bazate pe rulara finala):

Model	Accuracy	Recall	Precision	F1-Score	ROC-AUC
Logistic Regression	0.8006	0.9707	0.5094	0.6682	0.9276
Decision Tree	0.8541	0.8904	0.5990	0.7162	0.9380
Random Forest	0.9003	0.8271	0.7279	0.7743	0.9595
XGBoost	0.8897	0.8383	0.6928	0.7586	0.9574

Table 1: Rezultate experimentale finale pe setul de test

Analiza rezultatelor evidentiaza un contrast clar intre modelele testate: Logistic Regression domina la capitolul Recall (97.07%), demonstrand o capacitate exceptionala de a detecta aproape toate atacurile, insa cu pretul unei precizii scazute (50.94%). Aceasta "paranoia" a modelului liniar este explicata prin impingerea granitei de decizie in favoarea clasei minoritare in urma aplicarii SMOTE, ceea ce in realitate ar genera un volum ridicat de alarme false, obositor pentru un analist SOC. In contrast, Random Forest ofera cel mai bun echilibru operational, atingand cea mai mare acuratete (0.90) si cel mai mare F1-Score (0.77); capacitatea arborilor de decizie de a crea granite non-liniare complexe permite o precizie superioara (72.79%) prin izolarea mai eficienta a traficului normal care simuleaza comportamentul de Fuzzer. In final, valorile ROC-AUC de peste 0.92 pentru toti algoritmi confirma faptul ca, in ciuda dificultatilor de a echilibra precizia si rata de detectie, capacitatea intrinseca a modelelor de a distinge intre pachetele legitime si cele malitioase ramane excelenta.